

vLLM GPU Prefix Cache 與 External KV 命中分析

A3 從 external cache 補回 5,328 tokens ;
三類觀測資料共同確認分層 cache 行為。

● EVIDENCE ALIGNED / READY TO SHARE

A1

COLD PREFILL

A2

GPU HIT

B1


EVICTION

A3

EXTERNAL HIT

A3 / CACHE TIER CONTRIBUTION

99.987% REUSED



7,712 REUSED TOKENS



COMBINED PREFIX REUSE
ONLY 1 TOKEN RECOMPUTED

7,712

A1 COLD



1.651s

A3 EXT



0.490s

TECHNICAL SUMMARY

這次實驗確認了 GPU 與 external KV 的分層命中

A3 / COMBINED REUSE

7,712

GPU 保留 2,384 tokens，external cache 補回 5,328 tokens；7,713-token Prompt 最後只需重新計算 1 token。

external KV connector 在 A3 有實際貢獻；但 external hit 尚不能嚴格等同「實體 SSD read」。

A2 / PURE GPU HIT

7,712

幾乎完整由本機 GPU Prefix Cache 重用。

A3 / EXTERNAL HIT

5,328

補回被 B1 容量壓力淘汰的 Prefix A blocks。

PREFILL ORDER

A2 < A3 < Cold


延遲排序符合 GPU、external、冷算的成本差異。

WHY EVICTION SHOULD HAPPEN

GPU 只能容納 10,016 tokens ; A 與 B 無法完整共存

GPU TOKEN CAPACITY

10,016



B1 進入後，GPU 必須回收 Prefix A 的多數 blocks ; A3 才能測試 external KV 是否補回缺口。

AVAILABLE KV CACHE

4.74 GiB

Gemma 3 27B weights : 51.45 GiB

KV BLOCK SIZE

16

626 GPU blocks $\times$ 16 = 10,016 tokens

MAX MODEL LEN

8,192

單次長 Prompt 接近 context 上限

EXTERNAL KV TIER

100 GB

aiDAPTIVLink SSD KV cache offload

CONTROLLED SEQUENCE

四個 Request，各自回答一個 cache 狀態問題

Prefix A 為 7,713 tokens；Prefix B 為 7,611 tokens。四次皆使用相同模型、chat template 與 request 設定。

A1

COLD / BUILD

第一次送 A。local 與 external 都應為 0，並建立可重用 Prefix KV。

A2

GPU LOCAL HIT

再次送相同 A。驗證 GPU Automatic Prefix Caching。

B1

CAPACITY PRESSURE

送完全不同的 B，迫使 GPU 回收 Prefix A 的多數 blocks。

A3

EXTERNAL RESTORE

再送 A。觀察 GPU 尚存 Prefix 與 external KV 共同命中。

THREE INDEPENDENT VIEWS

API、middleware log、Prometheus 各自回答不同問題

API schema 的 `cached_tokens` 為 `null`，因此 cache 層級不能只靠 request response 判斷。

API

Request response

確認 Prompt/Generation tokens，以及 client、prefill、decode、inference、server e2e latency。

```
prompt_tokens
metrics.prefill_time
metrics.e2e_latency
```

LOG

Middleware log

用 response ID 對齊 request，觀察 GPU hit、aiDAPTIVCache match 與 store 路徑。

```
GPU cache hit
aiDAPTIVCache hit
skip_leading_tokens
```

PROM

vLLM metrics

以五個 snapshot 的 Counter 差值，精確還原 local 與 external hit tokens。

```
prefix_cache_hits_total
external_prefix_cache_hits_total
queries_total
```

判讀原則：API 看效能，middleware 看路徑，Prometheus Counter 看互斥命中貢獻。

MEASUREMENT METHOD

每次 Request 的命中數，必須用相鄰快照相減



$$\begin{aligned} A1 &= M1 - M0 & A2 &= M2 - M1 \\ B1 &= M3 - M2 & A3 &= M4 - M3 \end{aligned}$$

M0 已含 7 個 Prompt/query tokens 與 10 個 Generation tokens。不能把 M4 絕對值直接當成本輪結果。

API RESPONSE EVIDENCE

Prefill latency 呈現清楚的 cache 層級成本

PREFILL TIME / SECONDS

LOWER IS BETTER

A1 COLD		1.651
A2 GPU		0.155
B1 COLD		1.616
A3 EXT		0.490

A2 GPU hit 最快；A3 external restore 次之；A1/B1 冷算最慢。

A2 VS A1

-90.634%

純 GPU local hit 幾乎消除 Prefix prefill。

A3 VS A1

-70.313%

External 載入仍遠快於重新計算完整 Prefix。

A3 / A2

3.170×

External restore 有資料搬移與 connector 成本。

PROMETHEUS CUMULATIVE VALUES

五份快照的 labels 與建立時間一致

model_name 均為 gemma3-27b-with-middleware；期間沒有觀察到 vLLM restart 或 Counter reset。

Snapshot	Prefix queries	Local hits	External queries	External hits	Prompt	Generation
M0	7	0	7	0	7	10
M1	7,720	0	7,720	0	7,720	12
M2	15,433	7,712	15,433	0	15,433	14
M3	23,044	7,712	23,044	0	23,044	17
M4	30,757	10,096	30,757	5,328	30,757	19

所有 _created series 只是 Counter 建立時間，不代表 Cache 建立或命中數量。

PER-REQUEST RECONSTRUCTION

A2 是純 GPU hit ; A3 是 local + external 混合命中

A1

7,713 QUERIED

COLD · 7,713

0.000% REUSED**A2**

7,713 QUERIED

GPU · 7,712

99.987% REUSED**B1**

7,611 QUERIED

COLD · 7,611

0.000% REUSED**A3**

7,713 QUERIED

EXT · 5,328

GPU · 2,384

99.987% REUSED

EXACT RECONCILIATION

兩層 Cache 的 token 數可以精確對帳

A3 / TOKEN LEDGER

BLOCK SIZE = 16

GPU local hit	2,384
External hit	5,328
Combined reuse	7,712
Prompt tokens	7,713
Recompute	1

A3 / PREFIX CONTRIBUTION

99.987%



7,712 tokens 構成完整可重用 blocks；最後 1 token 位於未完成 block，需重新處理以取得 logits。

WHAT ACTUALLY HAPPENS

External 命中的 KV 會先回補 GPU，再供 Attention 使用

01

找到 local Prefix

vLLM 先辨識 GPU 上仍保留的 2,384-token Prefix。

02

查到 external KV

KV Connector 找到其後 5,328 tokens 的 external blocks。

03

配置 GPU blocks

vLLM 為 external KV 準備 GPU KV buffer 空間。

04

載入 KV tensors

Middleware 將外部 KV 載入；實作也可能逐 layer pipeline。

05

計算最後 1 token

7,712-token Prefix 就緒後，只處理尾端 token，再進入 decode。

不是把 local 與 external 的數字相加後「直接推論」；兩者提供的是 Attention 真正使用的 KV tensors。

INDEPENDENT VALIDATION

累積 hit rate 在兩個來源中完全一致

Local Prefix Cache

32.833%

Prometheus : 10,096 local hit tokens ÷ 30,750 queried tokens ◦

Middleware display: 32.8%

External Prefix Cache

17.327%

Prometheus : 5,328 external hit tokens ÷ 30,750 queried tokens ◦

Middleware display: 17.3%

A3 store path

skip = 7,712

Middleware 只需處理尾端 1 / 7,713 ; 與 combined reuse 完全一致 ◦

Latency ordering

A2 < A3 < cold

API prefill time 以效能結果支持相同 cache 層級判讀 ◦

FOUR COMMON TRAPS

不要把「查詢、命中、store、usage」混為同一件事

01 / QUERY ≠ READ

External query 不等於 SSD read

A2 也增加完整 external queries，但 external hits 增量為 0；query 只是 connector 查詢或統計。

02 / MATCH ≠ CONTRIBUTION

Middleware aiDAPTIVCache hit 不一定是 SSD 貢獻

A2 顯示可匹配 7,712，但實際貢獻全由 GPU；互斥 external contribution 是 0。

03 / STORE ≠ WRITE BYTES

進入 store 路徑不代表真的寫入同等 SSD bytes

可能只是 write-through、refresh、deduplication 或 metadata update；需底層 I/O counter 驗證。

04 / IDLE GAUGE ≠ EMPTY

kv_cache_usage_perc = 0 不代表 Prefix Cache 為空


快照取於 Running: 0；A2 的 7,712-token GPU hit 已證明 idle cache 仍可重用。

GRANULARITY AND CONFIDENCE

Generated tokens 會占 KV；但不會增加下次共同 Prefix

PROMPT BLOCKS / CONCEPTUAL

16 TOKENS EACH



- 7,712 tokens 可形成完整可重用 blocks。
- 最後 1 個 Prompt token 需重新處理。
- A1/A2/B1/A3 只生成 2、2、3、2 tokens，容量影響很小。
- 先前生成的 READY 不屬於下一次 A Prompt，因此不計入 Prefix hit。

尚未嚴格證明

- External hit 是否每次都對應實體 SSD read。
- Store 路徑是否真的產生 SSD write bytes。
- A3 載回 blocks 是否在完成後完整保留於 GPU。
- Request 執行期間的瞬時 KV usage 峰值。

可信度：Ready to share with stated caveats。

FINAL ASSESSMENT

External KV 已證實有貢獻；下一步要證明實體 I/O

A3 將 GPU 尚存的 **2,384** tokens，與 external 補回的 **5,328** tokens 合併。

結果是 7,712 / 7,713 tokens 重用，prefill 從冷算 1.651 秒降至 0.490 秒。API、middleware 與 Prometheus 三者共同支持這個結論。

● LAYERED PREFIX CACHE BEHAVIOR CONFIRMED

NEXT / A4

再送一次 A

確認 A3 載回的 blocks 是否轉為完整 GPU local hit。

NEXT / STORAGE I/O

收集 read/write bytes

區分 connector hit 與實際 SSD 存取。

SOURCE REPORT

2026-08-05

Gemma 3 27B • H200 • aiDAPTIVLink